

데이터 수집 및 외부 파이프라인 정의서.

실시간 주가 지수, 종목 토론방 감성 키워드, 수급 및 뉴스 데이터를 안정적으로 수집하고 외부 장애에 대응하기 위한 파이프라인 및 스크래핑 명세를 정의한다.

DOCUMENT
SYS-PIPE-01

TECH STACK
Python / BS4 / FDR

MODULE SCOPE
core/data_sources/ ·
scraper/

VERSION
v1.0

01 외부 데이터 원천 및 수집 명세

시스템에서 사용하는 4가지 주요 외부 데이터 수집 원천의 프로토콜, 항목, 수집 주기 및 캐시 TTL을 정의한다.

수집 대상	방식	원천 (SOURCE)	주요 수집 항목	수집 주기	CACHE TTL
시세 / 차트	API (FDR)	KRX / Yahoo Finance	일별/분별 OHLCV, 거래량, 이동평균선 데이터	실시간 / 조회시	10 min
종목 토론방	Scraper	네이버 페이 증권 (Finance)	게시글 제목/본문, 공포·탐욕 키워드, 조회수, 작성시간	5분 주기 / 동적	5~10 min
수급 / 뉴스	Scraper	네이버 증권 / 뉴스 API	외국인·기관 순매수량, 주요 헤드라인, ESG/악재 여부	10분 주기	10 min
상장 종목 마스터	HTTP / JSON	KRX KIND / FDR	KOSPI, KOSDAQ, KONEX 전 종목 코드 및 기업명 매핑	일 1회 (배치)	12 hours

02 수집 파이프라인 단계별 처리 프로세스

외부 데이터를 수집하여 스코어링 엔진(core/)에 전달하기까지의 4단계 데이터 파이프라인 흐름.

STEP 01

Trigger & Request

종목 조회 시 st.cache_data 검증 후 외부 수집 세션 생성.

STEP 02

Fetch & Rate Limit

Random User-Agent 및 딜레이(0.3s) 적용 후 HTML/JSON 수집.

STEP 03

Parsing & Cleaning

BeautifulSoup 파싱, 불필요한 특수문자/광고 및 불용어 정제.

STEP 04

Validation & Store

Null/이상치 체크 후 데이터프레임 표준화 및 Cache 등록.

03 웹 스크래핑 세부 규칙 및 세션 관리

비공식 수집 경로의 안정성을 유지하기 위한 모듈별 세부 처리 규칙.



종목 토론방 크롤러

naver_scraper.py

- 페이지 동적 탐색: 게시글 밀도에 따라 상위 1~3페이지 파싱.
- 헤더 위장: Chrome/Firefox 최신 User-Agent 로테이션.
- 텍스트 정제: [광고], [스팸] 패턴 및 중복글 필터링.



외국인·기관 수급 크롤러

fundamentals.py

- 수급 데이터 수집: 최근 20거래일 외국인/기관 순매수 수량 및 금액.
- 예외 데이터 처리: 거래정지/신규상장 종목의 NaN 데이터 안전 처리.
- 지수 비교: KOSPI/KOSDAQ 동기간 수급과 대조하여 상대 강도 산출.

04 장애 대응(Fail-safe) 및 영속화 정책

네트워크 차단, API 장애, HTML DOM 구조 변경 등 예외 발생 시 서비스 지속성 확보.



Graceful Degradation

스크래핑 실패 시 중립 점수(Neutral Score: 50점)를 반환하여 가용성 보장.



Multi-Tier Fallback

FDR 실패 시 yfinance 자동 전환, 종목 목록 실패 시 로컬 20종목 풀백.



Score History Persistence

계산된 점수 이력은 data/score_history.json 파일에 영속화.